

## **AULA 2**


# **ESTRUTURA DAS REDES NEURAIS ARTIFICIAIS**

### **1. Objetivos**

- Mostrar analogia do sistema nervoso biológico com as RNAs.
- Apresentar estrutura das redes neurais artificiais (RNA):
  - Estrutura de um neurônio;
  - RNA de uma camada;
  - RNA de múltiplas camadas (deep-learning).
- Apresentar as funções de ativação.

### **2. Redes neurais biológicas**


- Um neurônio biológico possui 4 componentes principais (Figura 1):
  - Dendritos;
  - Corpo celular;
  - Axônio;
  - Terminações dos axônios (sinapses).
- Dendritos recebem sinais provenientes de outros neurônios.
- O corpo celular soma os sinais de entrada ⇒ quando a soma ultrapassa um determinado limite a célula dispara transmitindo um sinal para outros neurônios por meio do axônio.




**Figura1.** Esquema de um neurônio biológico (Gomes, I., Visão Geral de RN - <https://infosimples.com/artigos/visao-geral-redes-neurais>).

### 3. Estrutura das RNAs


- Principais características das redes neurais biológicas estão presentes nas RNAs:
  - Uma RNA consiste de uma grande quantidade de unidades de processamento simples (neurônios) interconectados;
  - Cada neurônio artificial recebe muitos sinais;
  - Cada neurônio é conectado a outros neurônios por meio de ligações;
  - Os sinais recebidos pelos neurônios são modificados por um peso nas sinapses receptoras;
  - Os neurônios artificiais somam as entradas multiplicadas por ganhos (pesos);
  - O neurônio artificial transmite uma única saída;
  - A saída de um neurônio é transmitida para muitos outros neurônios;
  - Cada ligação entre neurônios possui o seu peso (ganho);
  - Uma RNA pode possuir várias camadas de neurônios.
- Tipos de camadas de uma RNA:
  - Entrada;
  - Intermediária ou escondida;
  - Saída.
- Nas Figuras 2, 3 e 4 são mostrados exemplos de RNAs.



**Figura 2.** Exemplo de uma RNA de uma camada intermediária (escondida).



**Figura 3.** Exemplo de uma RNA de quatro camadas intermediárias (escondidas).




**Figura 4.** Exemplo de uma RNA de duas camadas intermediárias com duas saídas.

➤ **Aprendizado de uma RNA:**

- Os pesos das ligações representam a informação usada para resolver um problema;
- Aprender a solução de um problema  $\Rightarrow$  significa alterar os pesos das ligações;
- Aprendizado consiste em modificar os pesos das ligações de forma iterativa até a RNA ser capaz de reproduzir os dados usados no treinamento.

## 4. Estrutura de um neurônio

- Na Figura 5 é apresentado um esquema de um neurônio da primeira camada de uma RNA.
- Cada neurônio tem seu estado interno ( $z$ )  $\Rightarrow$  que é função das entradas recebidas.
- Cada neurônio tem o seu nível de ativação ( $a$ )  $\Rightarrow$  que é função das entradas recebidas, dos pesos de suas ligações e da sua função de ativação.
- Força da conexão entre neurônios consiste de um ganho específico para cada conexão.



**Figura 5.** Esquema de um neurônio da primeira camada intermediária.

➤ **Equações do neurônio da primeira camada intermediária:**

- Estado do neurônio ( $z$ )  $\Rightarrow$  somatória ponderada das entradas (no caso são as entradas da RNA):

$$\boxed{z = w_1x_1 + w_2x_2 + w_3x_3 + b} \quad (1)$$

onde:

$w_j$  = peso da ligação do neurônio com a entrada  $j$

$b$  = viés do neurônio

- Nível de ativação do neurônio ( $a$ ):

$$\boxed{a = g(z)} \quad (2)$$

onde  $g(z)$  = função de ativação do neurônio

➤ **Matricialmente:**

- Dimensões:
  - Número de entradas do neurônio  $\Rightarrow n_x$  (no caso é igual ao número de entradas da RNA)

- Vetor de entradas  $\Rightarrow$  dimensão  $(n_x, 1)$
- Vetor de pesos  $\Rightarrow$  dimensão  $(1, n_x)$
- Viés, estado, nível de ativação e saída do neurônio  $\Rightarrow$  escalares

- Equações:

$$\left\{ \begin{array}{l} z = \begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} + b \Rightarrow z = \mathbf{w}\mathbf{x} + b \\ a = g(z) \end{array} \right. \quad (3)$$

onde:


$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{(n_x, 1)} \Rightarrow \text{vetor de entradas}$$

$$\mathbf{w} = \begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix}_{(1, n_x)} \Rightarrow \text{vetor de pesos das sinapses}$$

Cada neurônio possui um vetor linha de pesos, com dimensão igual ao número de entradas do neurônio.

#### 4. RNA de uma única camada intermediária (RNA rasa)

- Na Figura 6 é apresentada uma RNA de uma única camada intermediária (RNA rasa).



**Figura 6.** RNA rasa de uma camada intermediária com 4 neurônios, 3 entradas e 2 saídas.

➤ **Equações da RNA:**

- Dimensões:
  - Número de entradas  $\Rightarrow n_x = 3$
  - Número de neurônios das camadas:
    - Primeira camada  $\Rightarrow n^{[1]} = 4$
    - Segunda camada  $\Rightarrow n^{[2]} = 2$
    - Número de estados = número de níveis de ativação = número de vieses = número de neurônios da camada
  - Matriz de pesos:
    - Primeira camada  $\Rightarrow$  dimensão  $(n^{[1]}, n_x) = (4, 3)$
    - Segunda camada  $\Rightarrow$  dimensão  $(n^{[2]}, n^{[1]}) = (2, 4)$
  - Número de saídas  $\Rightarrow n_y =$  número de neurônios da 2ª camada  $(n^{[2]} = 2)$
- Estados dos neurônios da primeira camada ( $\mathbf{z}^{[1]}$ ):

$$\begin{cases} z_1^{[1]} = w_{1,1}^{[1]}x_1 + w_{1,2}^{[1]}x_2 + w_{1,3}^{[1]}x_3 + b_1^{[1]} \\ z_2^{[1]} = w_{2,1}^{[1]}x_1 + w_{2,2}^{[1]}x_2 + w_{2,3}^{[1]}x_3 + b_2^{[1]} \\ z_3^{[1]} = w_{3,1}^{[1]}x_1 + w_{3,2}^{[1]}x_2 + w_{3,3}^{[1]}x_3 + b_3^{[1]} \\ z_4^{[1]} = w_{4,1}^{[1]}x_1 + w_{4,2}^{[1]}x_2 + w_{4,3}^{[1]}x_3 + b_4^{[1]} \end{cases} \Rightarrow \begin{bmatrix} z_1^{[1]} \\ z_2^{[1]} \\ z_3^{[1]} \\ z_4^{[1]} \end{bmatrix} = \begin{bmatrix} w_{1,1}^{[1]} & w_{1,2}^{[1]} & w_{1,3}^{[1]} \\ w_{2,1}^{[1]} & w_{2,2}^{[1]} & w_{2,3}^{[1]} \\ w_{3,1}^{[1]} & w_{3,2}^{[1]} & w_{3,3}^{[1]} \\ w_{4,1}^{[1]} & w_{4,2}^{[1]} & w_{4,3}^{[1]} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} + \begin{bmatrix} b_1^{[1]} \\ b_2^{[1]} \\ b_3^{[1]} \\ b_4^{[1]} \end{bmatrix} \quad (4)$$

ou simplesmente:

$$\boxed{\mathbf{z}^{[1]} = \mathbf{W}^{[1]}\mathbf{x} + \mathbf{b}^{[1]}} \quad (5)$$

onde:

$w_{k,j}^{[1]}$  = peso da ligação do neurônio  $k$  da primeira camada com a entrada  $j$

$b_k^{[1]}$  = viés do neurônio  $k$  da primeira camada

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{(n_x,1)} = \text{vetor de entradas}$$

$$\mathbf{z}^{[1]} = \begin{bmatrix} z_1^{[1]} \\ z_2^{[1]} \\ z_3^{[1]} \\ z_4^{[1]} \end{bmatrix}_{(n^{[1]},1)} = \text{vetor de estados dos neurônios da primeira camada}$$

$$\mathbf{W}^{[1]} = \begin{bmatrix} w_{1,1}^{[1]} & w_{1,2}^{[1]} & w_{1,3}^{[1]} \\ w_{2,1}^{[1]} & w_{2,2}^{[1]} & w_{2,3}^{[1]} \\ w_{3,1}^{[1]} & w_{3,2}^{[1]} & w_{3,3}^{[1]} \\ w_{4,1}^{[1]} & w_{4,2}^{[1]} & w_{4,3}^{[1]} \end{bmatrix}_{(n^{[1]}, n_x)} = \text{matriz de pesos da primeira camada}$$

$$\mathbf{b}^{[1]} = \begin{bmatrix} b_1^{[1]} \\ b_2^{[1]} \\ b_3^{[1]} \\ b_4^{[1]} \end{bmatrix}_{(n^{[1]}, 1)} = \text{vetor de vieses dos neurônios da primeira camada}$$

- Nível de ativação dos neurônios da primeira camada ( $\mathbf{a}^{[1]}$ ):

$$\begin{cases} a_1^{[1]} = g^{[1]}(z_1^{[1]}) \\ a_2^{[1]} = g^{[1]}(z_2^{[1]}) \\ a_3^{[1]} = g^{[1]}(z_3^{[1]}) \\ a_4^{[1]} = g^{[1]}(z_4^{[1]}) \end{cases} \Rightarrow \begin{bmatrix} a_1^{[1]} \\ a_2^{[1]} \\ a_3^{[1]} \\ a_4^{[1]} \end{bmatrix} = g^{[1]} \left( \begin{bmatrix} z_1^{[1]} \\ z_2^{[1]} \\ z_3^{[1]} \\ z_4^{[1]} \end{bmatrix} \right) \Rightarrow \boxed{\mathbf{a}^{[1]} = g^{[1]}(\mathbf{z}^{[1]})} \quad (6)$$

onde:

$g^{[1]}$  = função de ativação da primeira camada

$$\mathbf{a}^{[1]} = \begin{bmatrix} a_1^{[1]} \\ a_2^{[1]} \\ a_3^{[1]} \\ a_4^{[1]} \end{bmatrix}_{(n^{[1]}, 1)} = \text{vetor de ativação dos neurônios da primeira camada}$$

- Estados dos neurônios da segunda camada ( $\mathbf{z}^{[2]}$ ):

$$\begin{cases} z_1^{[2]} = w_{1,1}^{[2]} a_1^{[1]} + w_{1,2}^{[2]} a_2^{[1]} + w_{1,3}^{[2]} a_3^{[1]} + w_{1,4}^{[2]} a_4^{[1]} + b_1^{[2]} \\ z_2^{[2]} = w_{2,1}^{[2]} a_1^{[1]} + w_{2,2}^{[2]} a_2^{[1]} + w_{2,3}^{[2]} a_3^{[1]} + w_{2,4}^{[2]} a_4^{[1]} + b_2^{[2]} \end{cases} \quad (7)$$

Matricialmente,

$$\begin{bmatrix} z_1^{[2]} \\ z_2^{[2]} \end{bmatrix} = \begin{bmatrix} w_{1,1}^{[2]} & w_{1,2}^{[2]} & w_{1,3}^{[2]} & w_{1,4}^{[2]} \\ w_{2,1}^{[2]} & w_{2,2}^{[2]} & w_{2,3}^{[2]} & w_{2,4}^{[2]} \end{bmatrix} \begin{bmatrix} a_1^{[1]} \\ a_2^{[1]} \\ a_3^{[1]} \\ a_4^{[1]} \end{bmatrix} + \begin{bmatrix} b_1^{[2]} \\ b_2^{[2]} \end{bmatrix} \Rightarrow \boxed{\mathbf{z}^{[2]} = \mathbf{W}^{[2]} \mathbf{a}^{[1]} + \mathbf{b}^{[2]}} \quad (8)$$

onde:

$w_{k,j}^{[2]}$  = peso da ligação do neurônio  $k$  da camada 2 com o neurônio  $j$  da primeira camada

$b_k^{[2]}$  = viés do neurônio  $k$  da segunda camada

$\mathbf{z}^{[2]} = \begin{bmatrix} z_1^{[2]} \\ z_2^{[2]} \end{bmatrix}_{(n^{[2]},1)}$  = vetor de estados dos neurônios da segunda camada

$\mathbf{W}^{[2]} = \begin{bmatrix} w_{1,1}^{[2]} & w_{1,2}^{[2]} & w_{1,3}^{[2]} & w_{1,4}^{[2]} \\ w_{2,1}^{[2]} & w_{2,2}^{[2]} & w_{2,3}^{[2]} & w_{2,4}^{[2]} \end{bmatrix}_{(n^{[2]},n^{[1]})}$  = matriz de pesos da segunda camada

$\mathbf{b}^{[2]} = \begin{bmatrix} b_1^{[2]} \\ b_2^{[2]} \end{bmatrix}_{(n^{[2]},1)}$  = vetor de vieses dos neurônios da segunda camada

- Nível de ativação dos neurônios da segunda camada ( $\mathbf{a}^{[2]}$ ):

$$\begin{cases} a_1^{[2]} = g^{[2]}(z_1^{[2]}) \\ a_2^{[2]} = g^{[2]}(z_2^{[2]}) \end{cases} \Rightarrow \begin{bmatrix} a_1^{[2]} \\ a_2^{[2]} \end{bmatrix} = g^{[2]} \left( \begin{bmatrix} z_1^{[2]} \\ z_2^{[2]} \end{bmatrix} \right) \Rightarrow \boxed{\mathbf{a}^{[2]} = g^{[2]}(\mathbf{z}^{[2]})} \quad (9)$$

onde:

$g^{[2]}$  = função de ativação da segunda camada

$\mathbf{a}^{[2]} = \begin{bmatrix} a_1^{[2]} \\ a_2^{[2]} \end{bmatrix}_{(n^{[2]},1)}$  = vetor de ativação dos neurônios da segunda camada

**⇒ Observe que as funções de ativações das diversas camadas em geral são diferentes.**

- Saídas da rede ( $\hat{\mathbf{y}}$ ):


$$\begin{cases} \hat{y}_1 = a_1^{[2]} \\ \hat{y}_2 = a_2^{[2]} \end{cases} \Rightarrow \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \end{bmatrix} = \begin{bmatrix} a_1^{[2]} \\ a_2^{[2]} \end{bmatrix} \Rightarrow \boxed{\hat{\mathbf{y}} = \mathbf{a}^{[2]}} \quad (10)$$

onde:

$\hat{\mathbf{y}} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \end{bmatrix}_{(n^{[2]},1)}$  = vetor de saída da RN

➤ Na Figura 7 é apresentado o fluxo de dados em uma RNA rasa.






**Figura 7.** Fluxo de cálculo da RNA rasa de uma camada intermediária.

## 5. RN de múltiplas camadas intermediárias (Deep-learning)

➤ Na Figura 8 é apresentada uma RNA deep-learning (ou profunda).



**Figura 8.** RNA deep-learning de  $L$  camadas.

➤ **Parâmetros e dimensões:**

- Número de entradas  $\Rightarrow n_x$
- Vetor de entradas  $\Rightarrow \mathbf{x}$ , dimensão  $(n_x, 1)$
- Número de saídas  $\Rightarrow n_y$
- Vetor de saídas  $\Rightarrow \hat{\mathbf{y}}$ , dimensão  $(n_y, 1)$
- Número total de camadas  $\Rightarrow L$  (número de camadas intermediárias  $\Rightarrow L - 1$ )
- Número de neurônios da  $l$ -ésima camada  $\Rightarrow n^{[l]}$
- Vetor de estados dos neurônios da  $l$ -ésima camada  $\Rightarrow \mathbf{z}^{[l]}$ , dimensão  $(n^{[l]}, 1)$
- Vetor de ativações dos neurônios da  $l$ -ésima camada  $\Rightarrow \mathbf{a}^{[l]}$ , dimensão  $(n^{[l]}, 1)$

- Matriz de pesos da  $l$ -ésima camada  $\Rightarrow \mathbf{W}^{[l]}$ , dimensão  $(n^{[l]}, n^{[l-1]})$
- Vetor de vieses da  $l$ -ésima camada  $\Rightarrow \mathbf{b}^{[l]}$ , dimensão  $(n^{[l]}, 1)$

➤ **Equações**

- Primeira camada:

$$\mathbf{z}^{[1]} = \mathbf{W}^{[1]}\mathbf{x} + \mathbf{b}^{[1]} \quad (11)$$

$$\mathbf{a}^{[1]} = g^{[1]}(\mathbf{z}^{[1]}) \quad (12)$$

- $l$ -ésima camada ( $l = 2, \dots, L$ ):

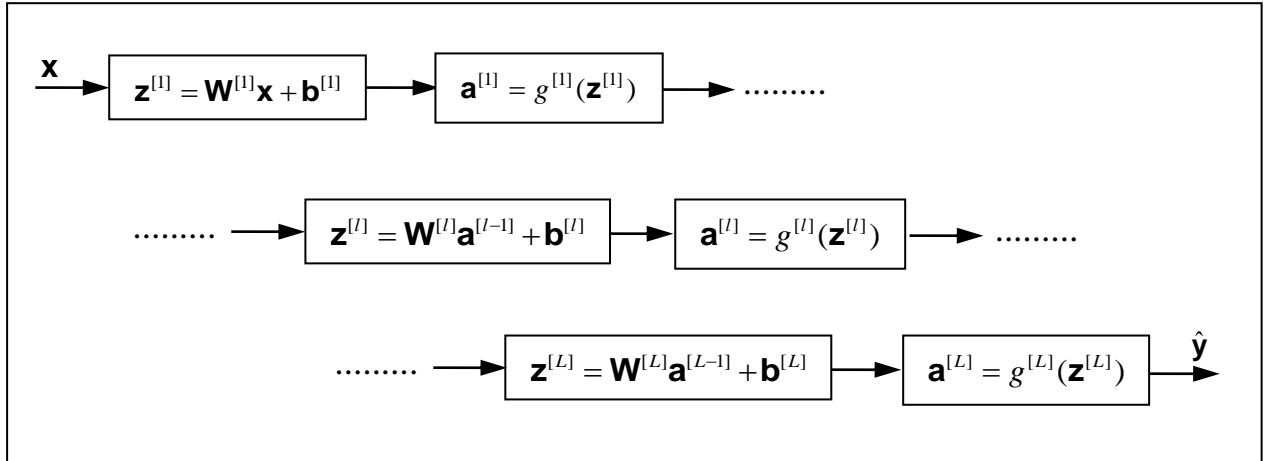
$$\mathbf{z}^{[l]} = \mathbf{W}^{[l]}\mathbf{a}^{[l-1]} + \mathbf{b}^{[l]} \quad (13)$$

$$\mathbf{a}^{[l]} = g^{[l]}(\mathbf{z}^{[l]}) \quad (14)$$

- Saídas:

$$\hat{\mathbf{y}} = \mathbf{a}^{[L]} \quad (15)$$

- O fluxo de dados em uma RNA deep-learning de  $L$  camadas é apresentado na Figura 9.



**Figura 9.** Fluxo de cálculo de uma RNA deep-learning de  $L$  camadas.

## 6. Nomenclatura geral

- Para facilitar o entendimento usamos uma notação matemática padrão para as RNAs.
- Comentários gerais:

- Superescrito  $(i) \Rightarrow i$ -ésimo exemplo de treinamento
- Superescrito  $[l] \Rightarrow l$ -ésima camada
- Subescrito  $k \Rightarrow k$ -ésimo elemento de um vetor
- Subescritos  $k, j \Rightarrow$  índice do elemento de uma matriz na  $k$ -ésima linha e  $j$ -ésima coluna

➤ Dimensões:

- $n_x \Rightarrow$  número de entradas de cada exemplo
- $m \Rightarrow$  número total de exemplos usados no treinamento
- $n^{[l]} \Rightarrow$  número de neurônios da  $l$ -ésima camada
- $L \Rightarrow$  número de camadas da RNA
- $n_y = n^{[L]} \Rightarrow$  número de saídas da RNA = número de neurônios da última camada ( $L$ )

➤ Parâmetros:


- $\mathbf{x}^{(i)} \Rightarrow i$ -ésimo vetor de entrada  $\rightarrow$  dimensão  $(n_x, 1)$
- $\mathbf{X} \Rightarrow$  matriz com todos os vetores de entradas  $\rightarrow$  dimensão  $(n_x, m)$
- $\mathbf{y}^{(i)} \Rightarrow i$ -ésimo vetor de saída  $\rightarrow$  dimensão  $(n_y, 1)$
- $\mathbf{Y} \Rightarrow$  matriz com todos os vetores de saídas  $\rightarrow$  dimensão  $(n_y, m)$
- $\mathbf{z}^{[l](i)} \Rightarrow$  vetor de estados dos neurônios da  $l$ -ésima camada referentes ao  $i$ -ésimo vetor de entrada  $\rightarrow$  dimensão  $(n^{[l]}, 1)$
- $\mathbf{Z}^{[l]} \Rightarrow$  matriz com todos os estados da  $l$ -ésima camada para todas as entradas  $\rightarrow$  dimensão  $(n^{[l]}, m)$
- $\mathbf{a}^{[l](i)} \Rightarrow$  vetor de ativações dos neurônios da  $l$ -ésima camada referentes ao  $i$ -ésimo vetor de entrada  $\rightarrow$  dimensão  $(n^{[l]}, 1)$
- $\mathbf{A}^{[l]} \Rightarrow$  matriz com todas as ativações da  $l$ -ésima camada para todas as entradas  $\rightarrow$  dimensão  $(n^{[l]}, m)$
- $\mathbf{W}^{[l]} \Rightarrow$  matriz de pesos da  $l$ -ésima camada  $\rightarrow$  dimensão  $(n^{[l]}, n^{[l-1]})$
- $\mathbf{b}^{[l]} \Rightarrow$  vetor de vieses da  $l$ -ésima camada  $\rightarrow$  dimensão  $(n^{[l]}, 1)$

## 7. Funções de ativação

- Existem diversos tipos de funções de ativação.
- Funções de ativação mais usadas:
- Linear;
  - Sigmóide;
  - Tangente hiperbólica;


- Unidade de retificação linear (“Retified Linear Unit” – **ReLU**);
  - Unidade de retificação linear fraca (“Leaky Retified Linear Unit” – **LeReLU**).
- Todos os neurônios de uma camada têm que ter a mesma função de ativação, mas cada camada da RNA pode ter uma função de ativação diferente.
- O tipo de função de ativação usado em uma RNA depende do problema que se deseja resolver.

## Função linear




$$a = z \quad (16)$$

## Função sigmóide



$$a = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (17)$$


## Função tangente hiperbólica



Tangente hiperbólica

$$a = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (18)$$

## Função ReLu




ReLu

$$a = \begin{cases} 0, & \text{para } z < 0 \\ z, & \text{para } z \geq 0 \end{cases} \quad (19)$$

$$a = \max(0, z)$$

## Função LeReLu




LeReLu

$$a = \begin{cases} 0,01z, & \text{para } z < 0 \\ z, & \text{para } z \geq 0 \end{cases} \quad (20)$$

$$a = \max(0,01z, z)$$

- Uma RNA não pode ter todas as suas camadas com funções de ativação linear.
- O que aconteceria se todas as funções de ativação fossem lineares?

Para responder essa pergunta vamos analisar a RN rasa mostrada na Figura 10.



**Figura 10.** Esquema de uma RNA rasa com 3 neurônios na camada intermediária.

Dado o vetor de entradas  $\mathbf{x}$ , a saída da RNA da Figura 10,  $\hat{y}$ , é dada por:

$$\begin{cases} \mathbf{z}^{[1]} = \mathbf{W}^{[1]} \mathbf{x} + \mathbf{b}^{[1]} \\ \mathbf{a}^{[1]} = g^{[1]}(\mathbf{z}^{[1]}) \\ z^{[2]} = \mathbf{W}^{[2]} \mathbf{a}^{[1]} + b^{[2]} \\ \hat{y} = a^{[2]} = g^{[2]}(z^{[2]}) \end{cases} \quad (21)$$

Se todas as funções de ativação fossem funções lineares, ou seja:

$$g^{[1]}(z) = g^{[2]}(z) = z \quad (22)$$

Tem-se para a primeira camada:

$$\mathbf{a}^{[1]} = \mathbf{z}^{[1]} = \mathbf{W}^{[1]} \mathbf{x} + \mathbf{b}^{[1]} \quad (23)$$

Para a segunda camada, tem-se:

$$a^{[2]} = z^{[2]} = \mathbf{W}^{[2]} \mathbf{a}^{[1]} + b^{[2]} \quad (24)$$

Substituindo  $\mathbf{a}^{[1]}$  na equação (24), obtém-se:

$$a^{[2]} = \mathbf{W}^{[2]} [\mathbf{W}^{[1]} \mathbf{x} + \mathbf{b}^{[1]}] + b^{[2]} \quad (25)$$

ou seja:

$$a^{[2]} = \underbrace{\mathbf{W}^{[2]} \mathbf{W}^{[1]} \mathbf{x}}_{\mathbf{W}' \mathbf{x}} + \underbrace{\mathbf{W}^{[2]} \mathbf{b}^{[1]} + b^{[2]}}_{b'} \quad (26)$$

Portanto, a saída de RNA é uma função linear dada por:

$$\hat{y} = a^{[2]} = \mathbf{W}' \mathbf{x} + b' \Rightarrow \text{função linear} \quad (27)$$

⇒ **Conclusão:**

- **Se as funções de ativação forem todas lineares a saída será sempre uma combinação linear das entradas**
- **RNA somente aprenderia funções lineares**
- **RNA muito limitada**

## **8. Aprendizado (treinamento) das RNAs**

- Para uma RNA ser capaz de resolver algum problema ela precisa ser treinada.
- O treinamento ou aprendizado consiste em determinar os parâmetros da RNA (matrizes  $\mathbf{W}^{[l]}$  e vetores  $\mathbf{b}^{[l]}$ , para  $l = 1, \dots, L$ ) para que a RNA seja capaz de resolver o problema desejado.
- **A pergunta que surge é: Como determinar os pesos da RNA?**

Por meio de um processo de otimização onde iterativamente são calculados os parâmetros para minimizar uma determinada função de custo.