

Aula 3

Redes Neurais Convolucionais #1



Eduardo L. L. Cabral



Objetivos


- Apresentar camada convolucional.
- Apresentar camada de “pooling”.
- Apresentar exemplo de uma RNA convolucional simples.
- Apresentar vantagens das RNAs convolucionais.

Camada convolucional

- Uma camada convolucional de uma RNA consiste de uma operação de convolução em um volume usando um conjunto de filtros de múltiplas dimensões.
- A diferença entre uma camada convolucional e um processo de convolução em volume é que na camada convolucional de uma RNA, é adicionado um viés e aplicada uma função de ativação no resultado do processo da convolução.

Camada convolucional

- Exemplo: entrada (8x8x3), com filtro (3x3x3x2), $p = 0$, $s = 1$:




Camada convolucional

- Camada convolucional do exemplo anterior:
 - Entrada $\Rightarrow \mathbf{a}^{[0]}$ = volume (8x8x3)
 - Filtros $\Rightarrow \mathbf{W}^{[1]}$ = volume (3x3x3x2), $p = 0$, $s = 1$, \mathbf{b} = vetor (2x1)
 - Saída $\Rightarrow \mathbf{a}^{[1]}$ = volume (6x6x2)
- Convolução é uma multiplicação de uma matriz por um vetor (operação linear).
- Equação da camada:

$$\begin{cases} \mathbf{z}^{[1]} = \mathbf{W}^{[1]} \mathbf{a}^{[0]} + \mathbf{b}^{[1]} \\ \mathbf{a}^{[1]} = g^{[1]}(\mathbf{z}^{[1]}) \end{cases}$$

Camada convolucional

- Camada convolucional \Rightarrow entrada $\mathbf{a}^{[0]}$ ($8 \times 8 \times 3$), filtros $\mathbf{W}^{[1]}$ ($3 \times 3 \times 3 \times 2$), com $p = 0$, $s = 1$, função de ativação \Rightarrow saída $\mathbf{a}^{[1]}$ ($6 \times 6 \times 2$)



- Se tivesse 10 filtros $\Rightarrow \mathbf{a}^{[1]}$ seria um volume ($6 \times 6 \times 10$)

Camada convolucional

- Exemplo de número de parâmetros de uma camada convolucional \Rightarrow camada com 10 filtros de dimensão 3x3x3:
 - Cada filtro tem $3 \times 3 \times 3 = 27$ parâmetros + 1 viés = total de 28 parâmetros;
 - Os 10 filtros tem $10 \times 28 = 280$ parâmetros.
- Fórmula geral para número de parâmetros de uma camada convolucional:

$$N = f^{[1]} \times f^{[1]} \times n_c^{[1-1]} \times n_f^{[1]} + n_f^{[1]}$$

- Não importa a dimensão da entrada da camada, o número de parâmetros da camada só depende da dimensão e do número de filtros.
- O mesmo conjunto de filtros pode ser usado para detectar características em imagens de qualquer dimensão.

Camada convolucional

- Notação e parâmetros da l -ésima camada convolucional:
 - Parâmetros da camada:
 - $f^{[l]}$ = dimensão dos filtros;
 - $p^{[l]}$ = tamanho do “padding”;
 - $s^{[l]}$ = “stride”;
 - $n_c^{[l]}$ = número de filtros (antigo n_f);
 - Filtros da camada:
 - Dimensão de cada filtro $\Rightarrow (f^{[l]} \times f^{[l]} \times n_c^{[l-1]})$;
 - $\mathbf{W}^{[l]}$ = parâmetros dos filtros, dimensão $(f^{[l]} \times f^{[l]} \times n_c^{[l-1]} \times n_c^{[l]})$;
 - $\mathbf{b}^{[l]}$ = vieses dos filtros, dimensão $(n_c^{[l]} \times 1) \Rightarrow$ tensor de dimensão $(1, 1, 1, n_c^{[l]})$.

Camada convolucional

- Notação e parâmetros da l -ésima camada convolucional:
 - Entrada da camada:
 $\mathbf{a}^{[l-1]} \Rightarrow$ tensor de dimensão $(n_H^{[l-1]} \times n_W^{[l-1]} \times n_C^{[l-1]})$
 Para m exemplos $\Rightarrow \mathbf{A}^{[l-1]}$ tensor de dimensão $(m \times n_H^{[l-1]} \times n_W^{[l-1]} \times n_C^{[l-1]})$.
 - Saída da camada (ativações):
 $\mathbf{a}^{[l]} \Rightarrow$ tensor de dimensão $(n_H^{[l]} \times n_W^{[l]} \times n_C^{[l]})$;
 Para m exemplos $\Rightarrow \mathbf{A}^{[l]}$ tensor de dimensão $(m \times n_H^{[l]} \times n_W^{[l]} \times n_C^{[l]})$.

$$n_{H,W}^{[l]} = \left\lfloor \frac{n_{H,W}^{[l-1]} + 2p^{[l]} - f^{[l]}}{s^{[l]}} + 1 \right\rfloor$$

n_H = altura do tensor, n_W = largura do tensor.

RNA convolucional simples

- Uma RNA convolucional pode ser formada por várias camadas convolucionais.
- Exemplo de uma RNA convolucional para tarefa de classificação:

– Imagens (64x64x3) \Rightarrow Entrada da RNA $\Rightarrow n_H^{[0]} = n_W^{[0]} = 64, n_c^{[0]} = 3$

– 1ª camada $\Rightarrow f^{[1]} = 3, s^{[1]} = 1, p^{[1]} = 0, n_c^{[1]} = 10$

Saída da 1ª camada \Rightarrow dimensão (62x62x10)

$$n_{H,W}^{[1]} = \left\lfloor \frac{n_{H,W}^{[0]} + 2p^{[1]} - f^{[1]}}{s^{[1]}} + 1 \right\rfloor = \left\lfloor \frac{64 + 0 - 3}{1} + 1 \right\rfloor = 62 \quad (n_H^{[1]} = n_W^{[1]} = 62, n_c^{[1]} = 10)$$

– 2ª camada $\Rightarrow f^{[2]} = 5, s^{[2]} = 2, p^{[2]} = 0, n_c^{[2]} = 20$

Saída da 2ª camada \Rightarrow dimensão (29x29x20)

$$n_{H,W}^{[2]} = \left\lfloor \frac{n_{H,W}^{[1]} + 2p^{[2]} - f^{[2]}}{s^{[2]}} + 1 \right\rfloor = \left\lfloor \frac{62 + 0 - 5}{2} + 1 \right\rfloor = 29 \quad (n_H^{[2]} = n_W^{[2]} = 29, n_c^{[2]} = 20)$$

RNA convolucional simples

- Exemplo de uma RNA convolucional para uma tarefa de classificação:

- 3ª camada $\Rightarrow f^{[3]} = 5, s^{[3]} = 2, p^{[3]} = 0, n_c^{[3]} = 40$

Saída da 3ª camada \Rightarrow dimensão (13x13x40)

$$n_{H,W}^{[3]} = \left\lfloor \frac{n_{H,W}^{[2]} + 2p^{[3]} - f^{[3]}}{s^{[3]}} + 1 \right\rfloor = \left\lfloor \frac{29 + 0 - 5}{2} + 1 \right\rfloor = 13 \quad (n_H^{[3]} = n_W^{[3]} = 13, n_c^{[3]} = 40)$$

- 4ª camada \Rightarrow camada de redimensionamento (“flattening”) da saída da 3ª camada para transformar o volume de dimensão (13x13x40) em um vetor de dimensão (6760x1) \Rightarrow objetivo é preparar a saída da 3ª camada para ser processada por uma camada densa.

Saída da 4ª camada \Rightarrow dimensão (6760x1)

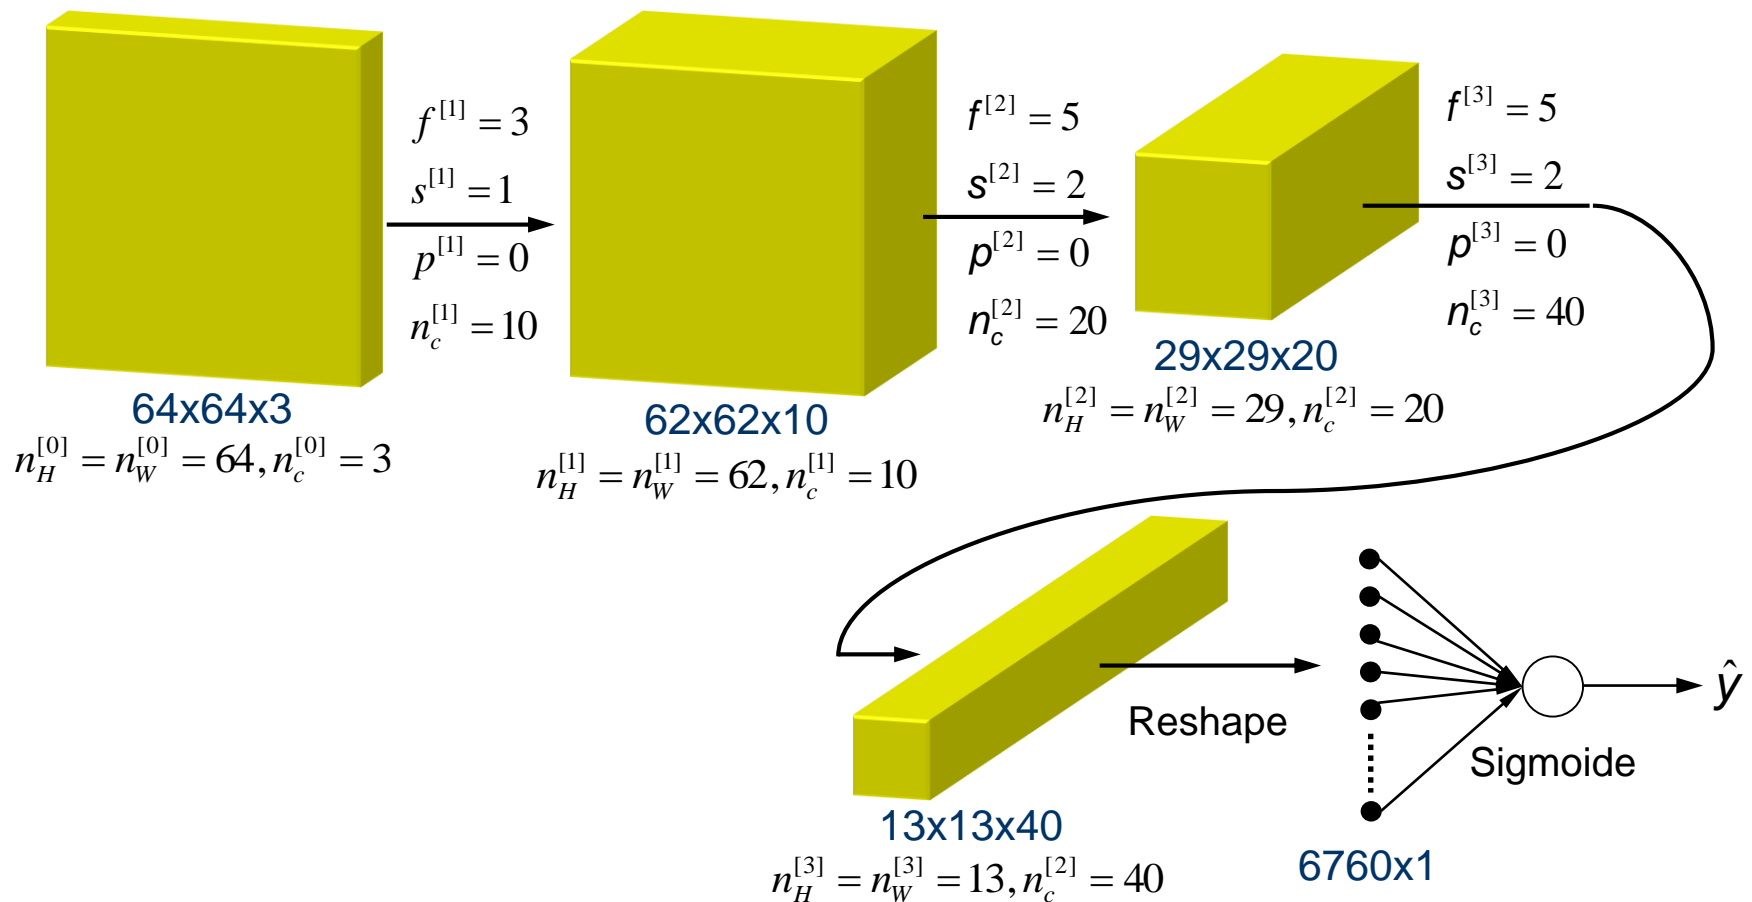
- 5ª camada (camada de saída) \Rightarrow camada densa de classificação:

Classificação binária \Rightarrow 1 neurônio com função de ativação sigmóide;

Classificação multiclasse \Rightarrow camada softmax.

RNA convolucional simples

- Exemplo de uma RNA convolucional para uma tarefa de classificação:



RNA convolucional simples


- Na configuração de uma RNA convolucional deve-se escolher os parâmetros da RNA \Rightarrow número de camadas (L), tamanhos dos filtros (f), número de filtros (n_c), “padding” (p), “strides” (s), função de ativação, como fazer?
 - Em geral dimensões das ativações diminuem na medida em que avançamos nas camadas da RNA.
- Tipos de camadas mais comuns em uma RNA convolucional:
 - Convolucional;
 - “Pooling”;
 - Totalmente conectada (densa).
 - Podem existir RNAs convolucionais sem camadas densas.

Camada de “pooling”

- Camadas de “pooling” são essenciais nas RNAs convolucionais.
- Uma camada de “pooling” é usada após uma operação de convolução para detectar onde na imagem uma determinada característica aparece com mais frequência e de forma mais ressaltada.
- Uma camada de “pooling” reduz o número de ativações.
- Existem dois tipos de camada de “pooling”:
 - “Max pooling” (seleção pelo máximo);
 - “Average pooling” (seleção pela média).
- Uma camada de “pooling” não tem parâmetros a serem treinados.


Camada de “max pooling”

- Hiperparâmetros da operação de “pooling”:
 - f = dimensão da janela;
 - s = deslocamento (“stride”) da janela.
- Exemplo de operação de “max pooling” ($f = 2$, $s = 2$)




Camada de “max pooling”

- O que a operação de “max-pooling” realiza:
 - Detecta a característica mais ressaltada dentro da janela;
 - Um valor grande significa que uma dada característica está mais presente;
 - Um valor pequeno significa que uma dada característica está menos presente;
 - A operação de “max-pooling” seleciona os locais da imagem onde uma dada característica está mais ressaltada.




Camada de “max pooling”

- Exemplo de “max-pooling” com $f = 3$ e $s = 1$:




Camada de “max pooling”

- Exemplo de “max-pooling” com $f = 3$ e $s = 1$:




Camada de “max pooling”

- Exemplo de “max-pooling” com $f = 3$ e $s = 1$:




Camada de “max pooling”

- Exemplo de “max-pooling” com $f = 3$ e $s = 1$:




Camada de “max pooling”

- Exemplo de “max-pooling” com $f = 3$ e $s = 1$:




Camada de “max pooling”

- Exemplo de “max-pooling” com $f = 3$ e $s = 1$:




Camada de “max pooling”

- Exemplo de “max-pooling” com $f = 3$ e $s = 1$:




Camada de “max pooling”

- Exemplo de “max-pooling” com $f = 3$ e $s = 1$:



Camada de “max pooling”

- Exemplo de “max-pooling” com $f = 3$ e $s = 1$:




Camada de “max pooling”

- Operação de “pooling” em um volume:
 - Em cada canal do volume de entrada a operação de “pooling” é realizada de forma independente;
 - Preserva o número de canais do volume de entrada.
- Normalmente na camada de “pooling” usa-se “padding”, $p = 0$.
- Dimensão da saída de uma camada de “pooling” \Rightarrow fórmula para cálculo da dimensão da saída é a mesma que para uma camada convolucional ($p = 0$).

$$n_{H,W}^{[l]} = \left\lfloor \frac{n_{H,W}^{[l-1]} - f^{[l]}}{s^{[l]}} + 1 \right\rfloor$$

Camada de “average pooling”

- A operação de “average pooling” funciona quase da mesma forma que “max pooling”, mas na saída ao invés de se calcular o valor máximo na janela, calcula-se a média dos valores na janela.
- Exemplo de operação de “average pooling” ($f = 2$, $s = 2$)




Camada de “average pooling”

- A operação de “average pooling” não é muito usada nas RNAs.
- Operação de “max-pooling” é muito mais usada nas RNAs convolucionias, com exceção das redes muito profundas.
- A operação de “padding” é pouco usada nas camadas de “pooling”, mas pode ser utilizada.
- **Importante:**
 - Operação de “pooling” não altera número de canais;
 - Camada de “pooling” não tem parâmetros para aprender.

Exemplo de RNA convolucional

- Rede LeNet-5 usada para classificação de dígitos em imagens coloridas.
- Arquitetura:
 - Dimensão das imagens de entrada $\Rightarrow 32 \times 32 \times 3$;
 - Duas camadas convolucionais, seguidas de camadas de “max-pooling”;
 - Duas camadas densas e uma camada softmax;
 - Todos os “paddings” são iguais a zero.

RNA convolucional LeNet-5



RNA convolucional LeNet-5

Camada	Dimensão	Número de ativações	Número de parâmetros
Entrada	(32,32,3)	3,072	0
Convolução 1 ($f=5$, $s=1$, $p=0$, $n_c=8$)	(28,28,8)	6,272	608
“Pooling” 1 ($f=2$, $s=2$)	(14,14,8)	1,568	0
Convolução 2 ($f=5$, $s=1$, $p=0$, $n_c=16$)	(10,10,16)	1,600	3.216
“Pooling” 1 ($f=2$, $s=2$)	(5,5,16)	400	0
Redimensionamento	(400x1)	400	0
Densa 1	(120,1)	120	48.120
Densa 2	(84,1)	84	10.164
Softmax	(10,1)	10	850

RNAs convolucionais

- Arquitetura comum nas RNAs convolucionais:
conv + pool → conv + pool → conv + pool → camadas densas → camada de classificação
 - Número de ativações das camadas diminui muito com a profundidade.
 - Camadas densas tem muitos parâmetros.
 - Camadas convolucionais tem poucos parâmetros.
 - Camadas “pooling” não tem parâmetros.
- Uma RNA convolucional tem muitos hiperparâmetros \Rightarrow dificuldade de criar uma RNA convolucional é grande.
- É difícil combinar todos esses tipos de camadas e definir seus hiperpâmetros de forma que a rede consiga realizar a sua tarefa com o desempenho desejado.

RNAs convolucionais

- No lugar de se criar uma nova RNA convolucional o ideal é analisar RNAs convolucionais existentes, que apresentam bom desempenho e a partir dessas modificá-las.
- **Cuidado** \Rightarrow confusão de nomenclatura;
 - Convenção #1 \Rightarrow denominar uma camada convolucional seguida de uma camada de “pooling” como sendo somente uma única camada.
 - Convenção #2 \Rightarrow a camada convolucional seguida de uma camada de “pooling” são consideradas duas camadas.
 - Essas duas convenções são usadas normalmente.

Vantagens das RNAs convolucionais

- RNAs convolucionais são usadas para:
 - Processamento de imagens;
 - Processamento de séries temporais.
- A grande vantagem das RNAs convolucionais é o compartilhamento de parâmetros:
 - Uma camada densa para processar uma imagem de dimensão $32 \times 32 \times 3$ (3.072 entradas) e produzir uma saída de 6.272 ativações possui $3.072 \times 6.272 + 6.272 = 19.273.856$ parâmetros \Rightarrow uma quantidade muito grande para uma imagem pequena.
 - Uma camada convolucional com 8 filtros de dimensão 5×5 usada para processar a mesma imagem e produzir uma saída com mesmo número de ativações 6.272 (dimensão $28 \times 28 \times 8$) possui $5 \times 5 \times 3 \times 8 + 8 = 608$ parâmetros.

Vantagens das RNAs convolucionais

- Razões para uma camada convolucional possuir poucos parâmetros:
 - Compartilhamento de parâmetros \Rightarrow um filtro usa os mesmos parâmetros para detectar uma determinada característica em toda a imagem;
 - Os mesmos tipos de características estão presentes em todas as imagens e em princípio em qualquer posição nas imagens;
 - Em uma imagem cada resultado de um filtro depende somente dos valores locais da imagem onde está posicionado o filtro.
- Uma RNA convolucional é invariante a translações \Rightarrow operação de convolução translada um filtro em toda a imagem detectando a presença de uma determinada característica.

Treinamento das RNAs convolucionais

- O treinamento de uma RNA convolucional é realizado da mesma forma que nas RNAs com somente camadas densas.
 - Define-se uma função de custo;
 - Escolha da função de custo depende da tarefa que se quer realizar;
 - Utiliza-se um algoritmo de otimização para minimizar a função de custo;
 - O resultado do treinamento é o cálculo de todos os parâmetros da RNA, que no caso das camadas convolucionais são os valores dos parâmetros dos seus filtros.